

Envejecimiento cerebral acelerado y reorganización topológica de redes en Latinoamérica

Cohorte BrainLat / ReDLAT — Análisis multimodal (fMRI · T1w · Cognición)

Objetivo central

Determinar si los cerebros con **Brain Age Gap (BAG) positivo** — es decir, cerebros que parecen más viejos de lo que realmente son — presentan una reducción en la **eficiencia local** de sus redes funcionales y en la **centralidad de los hubs frontoparietales**, estimado mediante análisis de grafos sobre matrices de conectividad funcional derivadas de fMRI en reposo, en participantes de la cohorte multicéntrica latinoamericana ReDLAT/BrainLat, controlando por edad cronológica, nivel educativo y sitio de adquisición.

Este documento describe, paso a paso, qué se hace en cada etapa del análisis y qué se espera obtener al finalizar cada una. Está pensado para que cualquier persona pueda entender el proceso aunque no conozca todos los detalles técnicos de la neuroimagen computacional.

PARTE 1 — ¿Con qué datos trabajamos?

Paso 1 — Exploración y auditoría de los datos

Antes de tocar ninguna imagen del cerebro, lo primero que se hace es revisar todas las tablas de información que existen sobre los participantes: sus datos demográficos (edad, sexo, años de educación, lugar de estudio), sus resultados en pruebas cognitivas (MoCA, IFS, mini-SEA) y qué tipos de imágenes tiene disponibles cada persona.

Se construye una única tabla maestra uniendo todas estas fuentes y se audita su completitud: cuántos valores faltan, cuántos participantes tienen resonancia magnética funcional en reposo (fMRI), cuántos tienen imágenes estructurales T1, y cuántos tienen ambas — porque solo quienes tienen ambas pueden entrar al análisis principal.

También se examina si los seis sitios de adquisición (Colombia, Brasil, México, Chile, Perú) son comparables en edad y nivel educativo, o si hay diferencias sistemáticas que deberán corregirse después. A esto se le llama **efecto de sitio** y es muy importante detectarlo temprano.

Herramientas: pandas, seaborn, pingouin, statsmodels

Resultado esperado:

Se conoce exactamente cuántos participantes están disponibles para cada análisis, cómo se distribuyen por diagnóstico (controles sanos, Alzheimer, demencia frontotemporal) y sitio, y si existen sesgos demográficos iniciales que deberán tenerse en cuenta en los pasos siguientes.

PARTE 2 — Procesamiento de las imágenes cerebrales

Paso 2 — Preprocesamiento con fMRIPrep

Las imágenes de resonancia magnética que salen del escáner están "crudas": tienen pequeños movimientos de cabeza, distorsiones geométricas y están en el espacio propio de cada escáner, lo que las hace incomparables entre sí.

El pipeline **fMRIPrep** resuelve todo eso automáticamente. Para cada participante: corrige los movimientos de cabeza (incluso movimientos de milímetros afectan la señal), registra el cerebro al espacio estándar **MNI152** (un cerebro promedio de referencia internacional) y separa la señal de la materia gris de las otras estructuras. El resultado son imágenes limpias, comparables entre todos los sitios.

Herramientas: fMRIPrep (pipeline externo)

Resultado esperado:

Cada participante cuenta con una imagen BOLD preprocesada lista para extraer conectividad funcional, más un mapa de probabilidad de materia gris que se usará para la volumetría.

Paso 3 — Volumetría de materia gris (VBM en Python)

La **Morfometría Basada en Vóxeles (VBM)** mide cuánta materia gris hay en cada punto del cerebro. Cuando las neuronas se pierden — como ocurre en el envejecimiento o en enfermedades como el Alzheimer — la materia gris se adelgaza y su volumen disminuye.

Se toma el mapa de probabilidad de materia gris que generó fMRIPrep, se aplica un suavizado espacial de **6 mm FWHM** (para reducir el ruido voxel a voxel y hacer las comparaciones más robustas) y luego se calcula el volumen total de materia gris de cada persona. Además, usando el atlas **AAL de 116 regiones**, se obtiene el volumen regional de cada área del cerebro por separado. Dos números resumen serán especialmente útiles más adelante: el volumen total y la media en las regiones frontales y parietales.

Herramientas: nibabel, nilearn (smooth_img, NiftiLabelsMasker), numpy

Resultado esperado:

Para cada participante se obtiene su volumen total de materia gris (en cm³) y el perfil de volumetría de las 116 regiones cerebrales del atlas AAL. Esto permite, entre otras cosas, detectar si los cerebros con envejecimiento acelerado muestran menor volumen en regiones críticas como el lóbulo frontal o parietal.

Paso 4 — Control de calidad de movimiento (QC)

Aunque fMRIPrep corrige el movimiento, los participantes que se movieron demasiado dentro del escáner producen señales funcionales irreparables. Se calcula para cada participante el **Framewise Displacement (FD)**, que mide cuánto se movió la cabeza entre cada par de imágenes consecutivas.

Se excluyen los participantes cuyo FD promedio supera los **0.5 mm** o que tienen más del **20%** de los volúmenes de tiempo con movimiento excesivo. Este filtro protege todos los análisis posteriores de confusiones entre "conectividad cerebral" y "artefacto de movimiento".

Herramientas: pandas, numpy, matplotlib

Resultado esperado:

Se obtiene el subconjunto de participantes cuya señal fMRI es suficientemente limpia para calcular conectividad funcional confiable. Se documenta cuántos participantes se pierden en este filtro y si el rechazo es uniforme entre diagnósticos y sitios.

PARTE 3 — Redes cerebrales funcionales

Paso 5 — Extracción de series temporales y matrices de conectividad funcional

El cerebro se divide en **116 regiones** usando el atlas **AAL (Automated Anatomical Labeling)**. Para cada región se extrae la señal BOLD promedio a lo largo del tiempo — esto es una **serie temporal**, una secuencia de números que representa la actividad de esa región segundo a segundo durante el reposo.

Antes de calcular la conectividad, se eliminan señales de ruido conocidas: los seis parámetros de movimiento y sus derivadas, más la señal de la materia blanca y el líquido cefalorraquídeo. Estas señales son contaminantes fisiológicos que no tienen que ver con la actividad neuronal real.

Con las series temporales limpias se calcula la **correlación de Pearson** entre cada par de regiones. El resultado es una **matriz de conectividad funcional** de 116×116, donde cada celda indica qué tan sincronizadas están dos regiones cerebrales: si siempre se activan juntas (correlación alta) significa que están "conectadas funcionalmente". La correlación se transforma con la función **Fisher-z** para estabilizar su distribución estadística.

Herramientas: nilearn (NiftiLabelsMasker, ConnectivityMeasure), numpy

Resultado esperado:

Cada participante tiene su propia matriz de conectividad funcional de 116×116, que resume cómo se comunica su cerebro. Esta matriz es el insumo central de todos los análisis de redes que vienen a continuación.

Paso 6 — Umbralización proporcional y construcción de grafos

Una red cerebral puede pensarse como un mapa de amigos: hay personas (regiones) y conexiones entre ellas. Pero no todas las correlaciones son igualmente confiables; muchas son muy pequeñas y podrían ser ruido.

La **umbralización proporcional** resuelve esto: para cada participante se conservan solo las **K% de conexiones más fuertes** y se descartan las demás. La matriz resultante es binaria: dos regiones están conectadas (1) o no (0). Se construyen grafos para densidades que van del **2% al 20%** en pasos del 1%, porque la biología del cerebro no opera en un único umbral fijo.

Al final de este paso, cada participante tiene **19 grafos binarios**, uno por cada nivel de densidad testado.

Herramientas: numpy, networkx

Resultado esperado:

Tenemos grafos matemáticos que representan la topología de la red cerebral de cada persona. Al usar múltiples densidades evitamos concluir cosas que solo serían ciertas para un umbral arbitrario.

Paso 7 — Extracción de métricas de teoría de grafos

Ahora que tenemos grafos, podemos calcular propiedades matemáticas que describen la organización de la red cerebral. Las métricas clave son:

Eficiencia local: mide qué tan bien conectados están los vecinos de cada nodo entre sí. Un cerebro eficiente localmente tiene regiones con muchas conexiones entre sus vecinos, lo que permite procesar información de forma redundante y resistente a fallos.

Eficiencia global: mide qué tan fácilmente puede viajar la información entre cualquier par de regiones del cerebro. Un cerebro eficiente globalmente puede integrar información de distintas áreas con rapidez.

Betweenness centrality de hubs frontoparietales: mide cuántos caminos cortos del cerebro pasan por las regiones frontoparietales. Si muchos caminos pasan por ahí, esas regiones son "hubs" — centros de comunicación vitales. En enfermedades neurodegenerativas y envejecimiento acelerado se espera que estos hubs pierdan su centralidad.

Para evitar depender de un único umbral, se calcula el **Área Bajo la Curva (AUC)** de cada métrica a lo largo del rango de densidades. Este número resume el comportamiento de la métrica en todo el espectro.

Herramientas: *bctpy (Brain Connectivity Toolbox), numpy*

Resultado esperado:

Para cada participante se obtiene un perfil de 6 métricas topológicas resumidas: eficiencia local, eficiencia global, coeficiente de clustering, más los mismos indicadores restringidos a los hubs frontoparietales. Estas métricas capturan si la red cerebral está bien organizada o si ha perdido su estructura jerárquica típica.

PARTE 4 — Preparación estadística y Brain Age Gap

Paso 8 — Armonización de sitio con neuroCombat

Los seis sitios de adquisición (Colombia, Brasil, México, Chile, Perú) utilizaron distintos escáneres de resonancia magnética con diferentes intensidades de campo y protocolos. Aunque fMRIPrep estandariza las imágenes, las métricas derivadas todavía pueden verse afectadas sistemáticamente por el sitio — un efecto técnico, no biológico.

El algoritmo **ComBat (neuroCombat)** elimina estos efectos de sitio de las métricas topológicas y de volumetría de manera estadística, preservando las diferencias reales de interés biológico (diagnóstico, edad, educación). Funciona como un "ecualizador" que pone a todos los sitios en el mismo idioma estadístico.

Herramientas: *neuroCombat, pingouin*

Resultado esperado:

Las métricas de cada participante quedan libres del efecto de sitio y pueden compararse directamente entre Colombia, Brasil, México, Chile y Perú. Se verifica que el efecto de sitio desaparece comparando un ANOVA antes y después de aplicar ComBat.

Paso 9 — Estimación del Brain Age Gap (BAG)

El **Brain Age Gap (BAG)** es la diferencia entre la **edad cerebral predicha** por un modelo de machine learning y la **edad cronológica real** de la persona. Un BAG positivo significa que el cerebro "parece" más viejo de lo que corresponde: tiene más señales de envejecimiento de las esperadas para su edad.

El modelo se entrena *solo con los controles sanos* (CN), usando como características (features) las métricas topológicas y de volumetría de materia gris armonizadas. Se usa el algoritmo **XGBoost** (o SVR como alternativa), que aprende a predecir la edad a partir del perfil de la red cerebral.

Para validar el modelo de forma honesta, se usa **Leave-One-Site-Out Cross-Validation (LOSO-CV)**: el modelo se entrena con los controles de 5 sitios y predice el sitio que quedó afuera, rotando los sitios. Así nunca predice con datos del mismo lugar con que entrenó, evitando sobreajuste geográfico.

Finalmente, se corrige el **sesgo de regresión a la media**: los modelos de edad cerebral tienden a sobrestimar la edad en personas jóvenes y subestimarla en personas mayores. Se ajusta este sesgo estadísticamente antes de calcular el BAG final.

Herramientas: XGBoost, scikit-learn (SVR, Pipeline, LOSO-CV), statsmodels

Resultado esperado:

Cada participante tiene asignado un valor de BAG (en años). Los participantes se clasifican en dos grupos: BAG+ (cerebro más viejo de lo esperado) y BAG- (cerebro en línea con su edad o más joven). Se reporta el rendimiento del modelo en los controles: R^2 y error absoluto medio (MAE).

PARTE 5 — Análisis estadístico e inferencias

Paso 10 — Comparación de métricas topológicas entre grupos BAG+ y BAG-

Con el BAG calculado, se puede responder directamente la pregunta central del proyecto: ¿los cerebros que envejecen más rápido de lo esperado (BAG+) tienen redes cerebrales peor organizadas?

Para cada métrica topológica se compara estadísticamente el grupo BAG+ contra el grupo BAG-, eligiendo la prueba según la distribución de los datos (**t-test** si es normal, **Mann-Whitney U** si no lo es). Para controlar el riesgo de encontrar diferencias por azar al hacer múltiples comparaciones, se aplica la corrección de tasa de falsos descubrimientos (**FDR de Benjamini-Hochberg**).

Además se comparan los tres diagnósticos entre sí (CN, Alzheimer, FTD) usando el test de **Kruskal-Wallis** con comparaciones post-hoc de Dunn.

Herramientas: pinguin, scipy, statsmodels (multipletests FDR)

Resultado esperado:

Se sabrá si el grupo BAG+ tiene significativamente menor eficiencia local y menor centralidad frontal-parietal que el grupo BAG-, incluso dentro del mismo diagnóstico. Este resultado es el núcleo de la hipótesis del proyecto.

Paso 11 — Regresión múltiple: topología ~ BAG + covariables

La comparación anterior separa por grupos, pero no cuantifica qué tan fuerte es la relación entre el BAG y cada métrica topológica. Para eso se ajusta un **modelo de regresión lineal múltiple** para cada métrica:

$$\text{métrica_topológica} = \beta_0 + \beta_1 \cdot \text{BAG} + \beta_2 \cdot \text{edad} + \beta_3 \cdot \text{educación} + \beta_4 \cdot \text{sexo} + \beta_5 \cdot \text{sitio} + \beta_6 \cdot \text{diagnóstico} + \text{error}$$

El coeficiente β_1 indica cuánto cambia la métrica por cada año adicional de BAG, controlando por todas las demás variables. Un β_1 negativo y significativo para la eficiencia local o la centralidad frontal-parietal confirmaría la hipótesis principal.

Herramientas: statsmodels (OLS), matplotlib

Resultado esperado:

Se obtiene la dirección (positivo/negativo) y magnitud del efecto del BAG sobre cada métrica de la red, independientemente de la edad cronológica, el sitio y el diagnóstico. Un "forest plot" visualiza los coeficientes con sus intervalos de confianza al 95%.

Paso 12 — Clasificación con Random Forest

Se entrena un modelo de **Random Forest** (un conjunto de árboles de decisión que votan por mayoría) para dos tareas distintas:

Tarea 1 — Diagnóstico: usando solo las métricas topológicas y volumétricas, ¿puede el modelo distinguir entre controles sanos, Alzheimer y FTD? Esto mide qué tan informativos son estos indicadores de red para identificar la enfermedad.

Tarea 2 — Grupo BAG: ¿puede el modelo distinguir a los BAG+ de los BAG-? Si puede hacerlo con buena exactitud, significa que la topología cerebral lleva una firma clara del envejecimiento acelerado.

En ambos casos se usa **validación cruzada estratificada de 5 pliegues** para estimar el rendimiento real del modelo. Se reporta el **AUC-ROC**, la exactitud y el F1 macro. También se analiza la importancia de cada feature para saber qué métrica aporta más información.

Herramientas: scikit-learn (RandomForestClassifier, StratifiedKFold), matplotlib

Resultado esperado:

Se conocerá qué tan bien predice la topología cerebral el diagnóstico y el grupo de envejecimiento. Se identificarán las métricas más relevantes: ¿es la eficiencia local? ¿la centralidad frontal-parietal? ¿el volumen de materia gris? Esto orienta qué features son los más informativos.

Paso 13 — Correlaciones parciales: topología × cognición

La pregunta final es si las diferencias en la red cerebral se traducen en diferencias en la cognición. Para esto se calculan **correlaciones parciales de Spearman** entre cada métrica topológica y cada score cognitivo (MoCA, IFS, mini-SEA), controlando por edad y educación.

La correlación parcial elimina el efecto de las covariables antes de calcular la asociación, por lo que muestra la relación "pura" entre red cerebral y cognición.

Los resultados se presentan en un **mapa de calor (heatmap)** que muestra todas las correlaciones a la vez, resaltando solo las que sobreviven la corrección FDR.

Herramientas: pingouin (partial_corr), seaborn, statsmodels

Resultado esperado:

Se identificará si los participantes con redes más eficientes o con hubs frontoparietales más fuertes tienen mejor desempeño cognitivo, independientemente de su edad y educación. Esto conectaría la reorganización topológica con el impacto funcional real en las capacidades mentales.

SÍNTESIS — ¿Qué se busca demostrar?

Todo el pipeline puede resumirse en una cadena de preguntas encadenadas:

1.	¿Cuántos cerebros disponemos y en qué condiciones están?	<i>Auditoría de datos (Paso 1)</i>
2.	¿Qué volumen de materia gris tiene cada cerebro?	<i>VBM en Python (Paso 3)</i>
3.	¿Cómo está conectado funcionalmente cada cerebro?	<i>Matrices FC + grafos (Pasos 5–7)</i>
4.	¿Cuánto "envejece más rápido" cada cerebro respecto a su edad?	<i>Brain Age Gap (Paso 9)</i>
5.	¿Los cerebros que envejecen más rápido tienen redes peor organizadas?	<i>Estadística inferencial (Pasos 10–11)</i>
6.	¿Pueden las métricas de red predecir el diagnóstico y el BAG?	<i>Machine Learning (Paso 12)</i>
7.	¿Las diferencias en la red se reflejan en la cognición?	<i>Correlaciones (Paso 13)</i>

Si la cadena es exitosa, el proyecto habrá demostrado que el **envejecimiento cerebral acelerado en Latinoamérica va acompañado de una degradación topológica específica**: las redes cerebrales pierden su eficiencia local y sus hubs frontoparietales pierden centralidad. Este hallazgo sería el primero de su tipo en una cohorte multicéntrica latinoamericana y conectaría la desigualdad socioeconómica regional con mecanismos neurobiológicos concretos.